

Sistema de Clasificación de Intenciones para un Asistente Virtual de Trámites Universitarios

Equipo 7

Gonzalo Nahuel Acosta Lopez, Cesar Pietro Barrios Calathaki

Departamento de Informática, FaCENA – UNNE

Corrientes, Argentina

gonzalinertolol@gmail.com, pietrocalathaki@gmail.com

Abstract—Este trabajo presenta el desarrollo de un asistente virtual conversacional para orientar a estudiantes de la FaCENA-UNNE en el trámite del Título Intermedio de Pregrado. Se implementaron y compararon tres modelos de clasificación de intenciones: Naive Bayes Multinomial con TF-IDF, SVM Lineal con TF-IDF y SVM con kernel RBF utilizando embeddings semánticos (SentenceTransformer). El modelo ganador alcanzó un 81.25% de exactitud y 0.81 de F1-macro, validado con 5-fold cross-validation. Se desarrolló una interfaz web funcional con Streamlit para su uso por la comunidad estudiantil.

I. INTRODUCCIÓN

A. Problema y Contexto

Los estudiantes de la UNNE que cursan carreras en la Facultad de Ciencias Exactas y Naturales y Agrimensura (FaCENA) enfrentan dificultades para comprender el proceso de obtención del Título Intermedio de Pregrado. El trámite involucra dos etapas con requisitos y plazos específicos que generan consultas recurrentes a la Dirección de Gestión de Estudios. Actualmente no existe un canal automatizado que resuelva estas consultas de forma inmediata.

B. Alcance

El sistema desarrollado es un asistente virtual capaz de interpretar preguntas en lenguaje natural y clasificarlas en 16 categorías (15 intenciones del trámite + fallback). Responde con información oficial basada en la resolución RES-2025-7936-REC-UNNE.

C. Tema Disciplinar

Este trabajo se enmarca en Procesamiento de Lenguaje Natural (NLP), específicamente en clasificación de textos cortos en el dominio administrativo-universitario.

D. Evolución respecto a la Asignatura

Este trabajo se basó en la prueba de un modelo no explorado durante la asignatura: SVM (Máquinas de Vectores de Soporte), además de aplicar herramientas nuevas relacionadas con el Procesamiento de Lenguaje Natural (PLN) como TF-IDF (modelos 1 y 2) y Embeddings semánticos (modelo 3).

II. MÉTODO

A. Metodología

Se adoptó un proceso iterativo basado en CRISP-DM adaptado para aprendizaje supervisado: 1) análisis del trámite y relevamiento de consultas, 2) curado y expansión del dataset con limpieza de texto, 3) modelado con tres arquitecturas de clasificación, y 4) evaluación con exactitud, F1-macro, 5-fold CV y GridSearchCV.

B. Modelos de IA

Se implementaron tres modelos supervisados de clasificación multiclase (Tabla I).

TABLE I
ARQUITECTURAS DE LOS MODELOS IMPLEMENTADOS.

Modelo	Vectorización	Hiperparámetros
M1: MultinomialNB	TF-IDF (unigramas)	$\alpha = 0.5$
M2: SVM Lineal	TF-IDF (unigramas)	$C = 1.0$, kernel = linear
M3: SVM RBF	SentenceTransformer (512-d)	$C = 10.0$, $\gamma = \text{scale}$

M1 utiliza Naive Bayes Multinomial con suavizado de Laplace ($\alpha = 0.5$), que modela la probabilidad condicional de cada término dada una clase. M2 emplea SVM lineal encontrando el hiperplano de separación óptimo. M3 utiliza SVM con kernel RBF sobre embeddings semánticos densos generados por distiluse-base-multilingual-cased-v2, capturando relaciones semánticas entre las consultas.

C. Experimentación

El dataset de 240 preguntas (16 por cada una de 15 intenciones) se dividió en 80% entrenamiento y 20% prueba (192/48), estratificado. Se realizaron tres fases experimentales: preprocesamiento (stemming, n-gramas, max features), optimización (GridSearchCV + 5-fold CV), y validación final (entrenamiento completo + prueba cualitativa).

III. HERRAMIENTAS

El sistema se desarrolló en Python 3.12. Las librerías principales se detallan en la Tabla II.

TABLE II
LIBRERÍAS Y HERRAMIENTAS UTILIZADAS.

Librería	Versión	Propósito
scikit-learn	1.6	Modelos (MultinomialNB, SVC), TfidfVectorizer, GridSearchCV
sentence-transformers	3.4	Embeddings semánticos multilingües
pandas / numpy	2.2 / 2.0	Manipulación de datos
joblib	1.4	Persistencia de modelos
streamlit	1.57	Interfaz web

TABLE III
EXPERIMENTOS DE PREPROCESAMIENTO (EXACTITUD SOBRE TEST).

Experimento	NB+TF-IDF	SVM+TF-IDF	SVM+Emb.
Baseline	77.08%	72.92%	81.25%
Con stemming	79.17%	70.83%	68.75%
Bigramas (1,2)	75.00%	72.92%	—

IV. RESULTADOS

A. Preprocesamiento

La Tabla III muestra el impacto de distintas técnicas.

El stemming beneficia a NB (+2.09%) pero degrada los modelos con embeddings (−12.5 pp). Los unigramas superan a los bigramas por menor dispersión con 240 muestras.

B. Optimización

La Tabla IV muestra los resultados de GridSearchCV.

TABLE IV
RESULTADOS DE GRIDSEARCHCV CON 5-FOLD CV.

Modelo	Mejores params	CV F1-macro
MultinomialNB	$\alpha = 0.5$	0.7063
SVM Lineal	$C = 1.0$	0.6872
SVM RBF	$C = 10.0, \gamma = \text{scale}$	0.7600

C. Resultados Finales

La Tabla V resume el desempeño final de los tres modelos.

TABLE V
RESULTADOS FINALES SOBRE EL CONJUNTO DE PRUEBA.

Modelo	Exactitud	F1-macro	F1-pond.
NB + TF-IDF ($\alpha = 0.5$)	79.17%	0.77	0.79
SVM Lineal + TF-IDF ($C = 1.0$)	75.00%	0.73	0.74
SVM RBF + Embeddings ($C = 10.0$)	81.25%	0.81	0.81

El modelo SVM con embeddings (M3) obtuvo el mejor desempeño. En una prueba cualitativa con 7 preguntas no incluidas en el dataset, clasificó 6 de 7 correctamente (85.71%).

La Figura 1 muestra la comparación de exactitud entre los tres modelos, y la Figura 2 presenta las matrices de confusión correspondientes.

V. CONCLUSIONES

A. Hallazgos

- 1) Los embeddings semánticos con SVM RBF superan a TF-IDF, alcanzando 81.25% de exactitud y 0.81 de F1-macro.
- 2) El stemming beneficia a NB (+2%) pero perjudica a embeddings (−12.5 pp), por lo que se descartó del pipeline final.
- 3) Con datasets pequeños (240 muestras), los unigramas son preferibles a bigramas por su menor dispersión.
- 4) GridSearchCV identificó configuraciones óptimas con mejoras de hasta 4 puntos respecto a valores por defecto.

B. Trabajos Futuros

- Expansión del dataset a 50+ preguntas por intención (750+ total) para mejorar la robustez del clasificador.
- Incorporación de técnicas de data augmentation y balanceo de clases.
- Integración con sistema de ticketing institucional para derivación de consultas no resueltas.
- Evaluación de modelos de lenguaje pre-entrenados (BERT, GPT) para clasificación few-shot.
- Expansión a otros trámites institucionales.

REFERENCES

- [1] S. Raschka y V. Mirjalili, *Python Machine Learning*, 3ra ed. Birmingham: Packt Publishing, 2019.
- [2] F. Pedregosa *et al.*, “Scikit-learn: Machine Learning in Python,” *JMLR*, vol. 12, pp. 2825–2830, 2011.
- [3] N. Reimers e I. Gurevych, “Sentence-BERT: Sentence Embeddings using Siamese BERT-Networks,” en *Proc. EMNLP-IJCNLP*, 2019, pp. 3982–3992.
- [4] C. Cortes y V. Vapnik, “Support-vector networks,” *Machine Learning*, vol. 20, no. 3, pp. 273–297, 1995.
- [5] Resolución RES-2025-7936-REC-UNNE. UNNE. Disponible: https://exa.unne.edu.ar/t/?page_id=9008




Fig. 1. Comparación de exactitud entre los tres modelos.




Fig. 2. Matrices de confusión. Izquierda: NB+TF-IDF ($\alpha = 0.5$). Centro: SVM Lineal+TF-IDF ($C = 1.0$). Derecha: SVM RBF+Embeddings ($C = 10.0$, $\gamma = \text{scale}$).